

به نام او

امتحان پایانترم درس مقدمه‌ای بر بیوانفورماتیک – ترم پاییز ۱۴۰۲ زمان: ۱۸۰ دقیقه

شماره دانشجویی:

نام و نام خانوادگی:

سوال (۱) گزاره‌ها مرتبط بین دو دسته اول و دوم را مشخص کنید. (زمان پیشنهادی: ۵ دقیقه) (۴ نمره)

دسته اول		دسته دوم	
گزاره	شناسه	گزاره	شناسه
فرایند ساخت پروتئین از روی RNA	الف	mRNA	۱
مولکولی که به آمینواسیدها متصل می‌شود و آن‌ها را به codonهای mRNA مرتبط می‌کند	ب	tRNA	۲
نوعی از RNA که کپی از ژن است و در فرایند ساخت پروتئین استفاده می‌شود	ج	rRNA	۳
فرایند کپی برداری از DNA برای ساخت نسخه دیگری از آن	د	transcription	۴
توالی‌های نوکلئیک اسیدی که در ساخت پروتئین نقش ندارند	ه	replication	۵
ماشین مولکولی که سنتز پروتئین‌ها را کاتالیز می‌کند	و	translation	۶
فرایند تولید دو رشته DNA یکسان از یک مولکول DNA	ز	exon	۷
توالی‌های نوکلئیک اسیدی که در ساخت پروتئین نقش دارند	ک	intron	۸

سوال (۲) یک گروه پژوهشی در یک نمونه‌گیری از خاک به مجموعه توالی زیر رسیده‌اند. آن‌ها قصد دارند تعداد گونه‌های این مجموعه را شناسایی و مورد مطالعه قرار دهند. فرض کنید شما عضوی از این گروه باشید، پس مراحل زیر را انجام دهید. (زمان پیشنهادی ۳۰ دقیقه)

مجموعه نمونه‌های استخراج شده از خاک:

ATA, AGT, AAC, CAT, TAG, GTG, TGG, CAG, GGT, ACA, TGC, AGG

الف. توالی‌های موجود در این نمونه را به دست آورید. برای این منظور مراحل assemble را نیز نشان دهید. (۸ نمره)

ب. در مرحله بعدی لازم است این توالی‌ها را مقایسه کنید و هم‌ترازی و ماتریس فاصله را برای این توالی‌ها گزارش کنید. برای این منظور کافی است هم‌ترازی دو به دو بین توالی‌ها انجام دهید. برای انجام این کار امتیازها را $mach = 1$ و $mismatch = -2$ و $gap = -1$ در نظر بگیرید. (نکته: برای این کار نیاز به گزارش ماتریس هم‌ترازی نیست ولی نحوه محاسبه امتیاز را نشان دهید). (۱۰ نمره)

ج. با توجه به بخش ب، ابتدا روش مناسب ساخت درخت فیلوژنی برای این توالی‌ها را انتخاب کنید و دلیل خود را شرح دهید. سپس برای ماتریس به دست آمده طبق آن درخت فیلوژنی رسم کنید. مراحل محاسبه این درخت را نیز نشان دهید. (۱۰ نمره)

سوال ۳) همان‌طور که می‌دانید بعضی از نواحی DNA از قطعات تکراری درست شده‌اند. مثلاً ممکن است یک قطعه DNA مثل TCCGGA صدها بار پشت سرهم یا با فواصل کوچک تکرار شود. ممکن است بعضی از این تکرارها دچار جهش یا حذف و اضافه هم بشوند. هدف از این سوال پیدا کردن چنین تکرارهایی است.

دو رشته ی DNA به طول m و n در اختیار داریم به طوری که رشته‌ی اول (ژنوم یک موجود) از رشته‌ی دوم (قطعه‌ای که به دنبال تکرارهای آن در ژنوم هستیم) بلندتر است. می‌خواهیم امتیاز تطابق رشته‌ی دوم با رشته‌ی اول را به دست بیاوریم به طوری که در این امتیازبندی رشته‌ی دوم می‌تواند به تعداد دفعات دل‌خواهی تکرار شود. فرض کنید تطابق به صورت ناحیه‌ای است و به ازای هر تغییر، اضافه و یا حذف کردن کاراکتر درون یک جایگاه برای رشته‌ی دوم یک امتیاز منفی و به ازای هر کاراکتر یکسان یک امتیاز مثبت در نظر گرفته می‌شود. اما برای فاصله‌های ایجاد شده قبل از اولین جایگاه و بعد از آخرین جایگاه و در بین دو جایگاه از رشته‌ی دوم امتیاز منفی‌ای در نظر گرفته نمی‌شود. برای حل این سوال از الگوریتم `dynamic programming` حداکثر با $O(m * n)$ استفاده کنید. (زمان پیشنهادی: ۲۵ دقیقه) (۱۸ نمره)

مثال : امتیاز دو رشته‌ی TACTACTAC و AC برابر با ۶ و امتیاز دو رشته‌ی TACTAGCT و AC برابر با ۳ است.

سوال ۴) با توجه به اینکه بعضی از variant‌های خاص در ژنوم باعث بعضی از بیماری‌ها می‌شوند (مثلاً تغییر G به C در پوزیشن ۲۲۱۲۵۵۰۴ در کروموزوم شماره ۹ باعث افزایش ریسک ابتلا به بیماری `coronary artery disease` می‌شود). چرا این variant‌های خاص در طول زمان و اثر انتخاب طبیعی از بین نرفته‌اند و هنوز در جامعه وجود دارند؟ دلایل خود را شرح دهید. (زمان پیشنهادی ۱۰ دقیقه) (۱۰ نمره)

سوال ۵) به سوالات زیر در مورد هم‌ترازی خوانش‌های کوتاه پاسخ دهید: (زمان پیشنهادی: ۱۵ دقیقه)

الف. در هم‌ترازی خوانش‌های کوتاه به دنبال حل چه مسأله یا مسائلی هستیم؟ (۲ نمره)

ب. مزیت استفاده از Suffix Trie نسبت به درخت Trie در حل مسئله‌ی Pattern Matching چیست؟ (۲ نمره)

ج. ارتباط بین BWT یک رشته و Suffix Array که برای همان رشته به دست می‌آید چیست؟ (۲ نمره)

د. تبدیل BWT قسمتی از ژنوم یک باکتری به صورت زیر است:

CGCAAAGA\$

می‌خواهیم تعداد و موقعیت خوانش GAA تولید شده از این رشته را به دست آوریم و می‌دانیم ممکن است در ژنوم یک جهش ایجاد شده باشد. لذا باید همه‌ی نقاطی از ژنوم اصلی را پیدا کنیم که حداکثر با یک جهش می‌توانند به رشته‌ی GAA تبدیل شوند. (۶ نمره)

سوال ۶) برای بررسی اینکه یک دارو باعث افزایش ضریب هوشی افراد می‌شود، ۱۲ نمونه کاملاً رندوم از افرادی که این دارو را مصرف کرده‌اند گرفته‌ایم. که میزان ضریب هوشی این افراد مطابق زیر است:

۹۲, ۱۱۰, ۱۰۱, ۱۰۷, ۱۱۵, ۱۰۶, ۹۴, ۹۹, ۱۲۰, ۱۰۱, ۱۱۱, ۱۱۶

با توجه به فرضیه‌های زیر تست آماری را انجام دهید و P-value آن را به دست آورید. همچنین نتیجه را توضیح دهید. (شرط رد کردن این فرض مقدار کمتر از ۰.۰۵ است) (جدول در صفحه آخر موجود است). (زمان پیشنهادی: ۲۰ دقیقه) (۱۵ نمره)

$H_0: \mu = 100$

$H_a: \mu > 100$

سوال ۷) مهدی که امسال درس مقدمه‌ای بر بیوانفورماتیک را دارد بعد از آشنایی با مفهوم genome assembly تصمیم گرفت که این مسئله را به روش greedy حل کند. او فرضیات زیر را در نظر گرفت:

$$L = \log \frac{G}{\epsilon}, \quad N = \frac{G}{L} \log \frac{G}{\epsilon}$$

که در آن N تعداد خوانش‌ها، L طول خوانش‌ها، G طول ژنوم که برابر با 3×10^9 و ϵ برابر با 10^{-3} است. با فرض مستقل بودن بازهای موجود در ژنوم (فرض iid) احتمال وقوع اولین خطا ترکیب دو خوانش را محاسبه کنید. (زمان پیشنهادی: ۲۵ دقیقه) (۱۵ نمره)

سوال ۸) فرض کنید نواحی intron و exon در افراد به این صورت است که با دانستن state جایگاه فعلی، state بعدی از سایر state‌های پیشین مستقل است. اگر ماتریس انتقال به صورت زیر باشد: (زمان پیشنهادی: ۴۰ دقیقه)

state	intron	Exon
intron	۰.۷	۰.۳
exon	۰.۸	۰.۲

و همچنین ماتریس انتشار به صورت زیر باشد:

State \ observe	A	C	G	T
intron	۰.۳	۰.۲	۰.۲	۰.۳
exon	۰.۲	۰.۳	۰.۳	۰.۲

الف. برای رشته ACCGTCA، محتمل‌ترین رشته‌ی حالات را محاسبه کنید. (۸ نمره)

ب. برای رشته‌ی گفته شده در قسمت الف محتمل‌ترین state برای جایگاه سوم را به دست آورید. (۸ نمره)

ج. آیا بیشینه حالت بدست آمده برای یک جایگاه با حالت به دست آمده برای آن جایگاه در قسمت الف حتماً برابر است؟ توضیح دهید. (۷ نمره)

د. احتمال دیدن رشته ACCTG را محاسبه کنید. (۵ نمره)

lookup table

cum. prob	t _{.50}	t _{.75}	t _{.80}	t _{.85}	t _{.90}	t _{.95}	t _{.975}	t _{.99}	t _{.995}	t _{.999}	t _{.9995}
one-tail	0.50	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.001	0.0005
two-tails	1.00	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.002	0.001
df											
1	0.000	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	318.31	636.62
2	0.000	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	22.327	31.599
3	0.000	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	10.215	12.942
4	0.000	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604	7.173	8.610
5	0.000	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032	5.893	6.869
6	0.000	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707	5.208	5.959
7	0.000	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.785	5.408
8	0.000	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355	4.501	5.041
9	0.000	0.703	0.883	1.100	1.383	1.833	2.262	2.821	3.250	4.297	4.781
10	0.000	0.700	0.879	1.093	1.372	1.812	2.228	2.764	3.169	4.144	4.587
11	0.000	0.697	0.876	1.088	1.363	1.796	2.201	2.718	3.106	4.025	4.437
12	0.000	0.695	0.873	1.083	1.356	1.782	2.179	2.681	3.055	3.930	4.318
13	0.000	0.694	0.870	1.079	1.350	1.771	2.160	2.650	3.012	3.852	4.221
14	0.000	0.692	0.868	1.076	1.345	1.761	2.145	2.624	2.977	3.787	4.140
15	0.000	0.691	0.866	1.074	1.341	1.753	2.131	2.602	2.947	3.733	4.073
16	0.000	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.686	4.015
17	0.000	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.646	3.961
18	0.000	0.688	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.610	3.922
19	0.000	0.688	0.861	1.066	1.328	1.729	2.093	2.539	2.861	3.579	3.883
20	0.000	0.687	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.552	3.850
21	0.000	0.686	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.527	3.819
22	0.000	0.686	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.505	3.792
23	0.000	0.685	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.485	3.768
24	0.000	0.685	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.467	3.745
25	0.000	0.684	0.856	1.058	1.316	1.708	2.060	2.485	2.787	3.450	3.725
26	0.000	0.684	0.856	1.058	1.315	1.706	2.056	2.479	2.779	3.435	3.707
27	0.000	0.684	0.855	1.057	1.314	1.703	2.052	2.473	2.771	3.421	3.690
28	0.000	0.683	0.855	1.056	1.313	1.701	2.048	2.467	2.763	3.408	3.674
29	0.000	0.683	0.854	1.055	1.311	1.699	2.045	2.462	2.756	3.396	3.659
30	0.000	0.683	0.854	1.055	1.310	1.697	2.042	2.457	2.750	3.385	3.646
40	0.000	0.681	0.851	1.050	1.303	1.684	2.021	2.423	2.704	3.307	3.551
60	0.000	0.679	0.848	1.045	1.296	1.671	2.000	2.390	2.660	3.232	3.460
80	0.000	0.678	0.846	1.043	1.292	1.664	1.990	2.374	2.639	3.195	3.416
100	0.000	0.677	0.845	1.042	1.290	1.660	1.984	2.364	2.626	3.174	3.390
1000	0.000	0.675	0.842	1.037	1.282	1.646	1.962	2.330	2.581	3.098	3.300
Z	0.000	0.674	0.842	1.036	1.282	1.645	1.960	2.326	2.576	3.090	3.291
	0%	50%	60%	70%	80%	90%	95%	98%	99%	99.8%	99.9%
	Confidence Level										